

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería



Convenio PLUS TI – Universidad del Valle 2025

Pedro Pablo Guzman - 22111

Javier Chen - 22153

Andre Yatmian Jo Mai – 22199

Security Data Science

Guatemala, Junio 2026

Resumen

Este trabajo se centró en la detección de fraude en transacciones financieras mediante dos enfoques complementarios. En la primera parte, se investigó el impacto de diferentes métricas personalizadas en LightGBM con el objetivo de reducir la cantidad de falsos positivos sin comprometer significativamente la capacidad de detección de operaciones fraudulentas. En la segunda parte, se desarrolló un modelo basado en aprendizaje federado utilizando información proveniente de dos instituciones financieras para generar inferencias sobre un tercer banco cuyos datos no incluían etiquetas de fraude.

Para ambas etapas se realizó un proceso de análisis exploratorio de datos, ingeniería de características y entrenamiento de modelos de aprendizaje automático. Posteriormente, se evaluaron distintas estrategias mediante métricas como ROC-AUC, Recall, Precision y F1-score. Los resultados obtenidos evidencian que la incorporación de información proveniente de múltiples entidades financieras mejora la capacidad de generalización del modelo, permitiendo identificar patrones de fraude incluso en datos no observados durante el entrenamiento.

Metodología

Parte A: Métricas personalizadas para la reducción de falsos positivos

Se utilizó un dataset sintético de transacciones financieras basado en el estándar ISO 8583, correspondiente a una entidad bancaria de Bolivia. Como primera etapa se realizó un análisis exploratorio de datos (EDA) para comprender la distribución de las variables, identificar posibles valores atípicos y analizar el desbalance existente entre transacciones legítimas y fraudulentas.

Posteriormente, se llevó a cabo un proceso de ingeniería de características orientado a capturar patrones de comportamiento asociados al fraude. Entre las variables generadas se incluyeron indicadores temporales, frecuencias de transacción en distintas ventanas de tiempo y medidas de desviación respecto al comportamiento histórico de cada cliente.

Como modelo base se empleó LightGBM, inicialmente evaluado mediante métricas tradicionales como ROC-AUC, Precision, Recall y F1-score. A partir de este modelo se diseñaron e implementaron funciones de evaluación personalizadas enfocadas en minimizar la proporción de falsos positivos, definida como:

$$FP / (TP + FP)$$

Cada estrategia fue evaluada utilizando el conjunto de prueba definido por la metodología del trabajo, comparando su capacidad para mantener altos niveles de detección de fraude mientras se reducía la generación de alertas incorrectas.

Parte B: Entrenamiento de un modelo federado

En la segunda etapa se trabajó con datasets etiquetados provenientes de dos bancos distintos, utilizados para el entrenamiento del modelo, mientras que un tercer banco fue reservado para la fase de inferencia y evaluación de generalización.

Con el fin de garantizar consistencia entre las fuentes de información, se aplicó el mismo proceso de limpieza, transformación e ingeniería de características a los tres conjuntos de datos. Posteriormente, se entrenaron modelos locales sobre cada banco y se exploraron distintas estrategias de agregación para construir un modelo federado capaz de capturar patrones de fraude compartidos entre instituciones con características y distribuciones diferentes.

Finalmente, el modelo federado seleccionado fue aplicado sobre el Dataset 3, generando una predicción binaria de fraude para cada transacción. Estas inferencias permitieron evaluar la capacidad del modelo para generalizar conocimiento hacia una entidad financiera que no participó directamente en el proceso de entrenamiento.

Descripción de la Implementación Práctica

La implementación se desarrolló en Python utilizando principalmente las bibliotecas Pandas, NumPy, Scikit-Learn, LightGBM e Imbalanced-Learn.

El flujo de trabajo consistió en:

1. Carga y exploración de los datasets.
2. Limpieza y transformación de variables.
3. Ingeniería de características orientadas a fraude.
4. División temporal de entrenamiento y prueba.
5. Entrenamiento de modelos LightGBM.
6. Implementación de métricas personalizadas mediante funciones feval.
7. Evaluación comparativa de resultados.
8. Construcción del modelo federado.
9. Generación de inferencias sobre el Dataset 3.

Durante el desarrollo también se realizaron pruebas de ajuste de hiperparámetros para optimizar el desempeño de los modelos y mejorar la capacidad de generalización.

Análisis de Resultados

Para evaluar las distintas estrategias de entrenamiento federado se compararon cinco modelos: Bolivia, Brasil, Global, Robust y FedAvg. La evaluación se realizó utilizando métricas estándar de clasificación (ROC-AUC, Recall, Precision y F1-score) y posteriormente mediante una configuración optimizada para garantizar una detección mínima del 90% de los fraudes.

En la evaluación estándar, el modelo Global presentó el mejor desempeño general, alcanzando un ROC-AUC de 0.8909, una precisión de 0.8295 y un F1-score de 0.6812. Estos resultados indican una mayor capacidad para distinguir entre transacciones legítimas y fraudulentas manteniendo un adecuado equilibrio entre detección y falsas alarmas.

El modelo Robust obtuvo el mayor Recall (0.5926), demostrando una mejor capacidad para identificar fraudes, aunque con una ligera reducción en precisión respecto al modelo Global. Por su parte, FedAvg logró resultados competitivos, evidenciando la efectividad de la agregación de conocimiento entre entidades financieras.

Posteriormente se evaluó una estrategia orientada a maximizar la detección de fraude, imponiendo una restricción de Recall superior al 90%. Bajo esta configuración, todos los modelos lograron superar el objetivo establecido. El modelo Robust alcanzó el Recall más alto (97.54%), mientras que el modelo Global obtuvo la mejor precisión dentro de este escenario (6.72%).

Los resultados muestran claramente el compromiso existente entre Recall y Precision. A medida que se incrementa la capacidad de detección de fraude, aumenta también la cantidad de falsos positivos generados. Este comportamiento es esperado en problemas altamente desbalanceados como la detección de fraude financiero.

En términos generales, el modelo Global fue seleccionado como la estrategia más equilibrada debido a que presentó el mejor desempeño global considerando simultáneamente capacidad discriminativa, precisión y estabilidad.

Dataset 3 con la Inferencia Realizada

El Dataset 3 corresponde a transacciones provenientes de una institución financiera de Guatemala y fue entregado sin la variable objetivo `is_fraud`. Luego de aplicar el modelo

federado entrenado con información de Bolivia y Brasil, se generaron predicciones para las 100,000 transacciones del conjunto de evaluación.

Se analizaron distintas estrategias de inferencia. El modelo Global clasificó como potencialmente fraudulentas 7,795 transacciones (7.79% del total), mientras que FedAvg identificó 11,504 transacciones (11.50%). El modelo Robust presentó una estrategia más agresiva de detección, marcando 54,481 operaciones como fraudulentas (54.48%).

Considerando los resultados obtenidos durante la validación federada, el modelo Global fue seleccionado como la alternativa más equilibrada para realizar la inferencia final sobre Guatemala, debido a su mejor combinación de ROC-AUC, Precision y F1-score.

Las predicciones generadas fueron exportadas a archivos de salida que contienen el identificador de transacción, la probabilidad estimada de fraude y la clasificación binaria correspondiente. Estos archivos se adjuntan como parte de la entrega final.

Conclusiones

En este trabajo se evaluaron distintas estrategias para la detección de fraude financiero utilizando modelos basados en LightGBM y técnicas de aprendizaje federado. Los resultados obtenidos demostraron que la incorporación de métricas personalizadas y el uso de información proveniente de múltiples entidades financieras permiten mejorar la capacidad de generalización del sistema.

En la primera parte del proyecto se comprobó que la selección de la función de evaluación tiene un impacto significativo sobre el comportamiento del modelo. Al priorizar la reducción de falsos positivos y mantener altos niveles de detección, fue posible identificar configuraciones más adecuadas para un entorno real de monitoreo de fraude, donde un exceso de alertas puede afectar la eficiencia operativa.

En la segunda parte se implementó un enfoque de aprendizaje federado utilizando información de dos bancos distintos para realizar inferencias sobre un tercer banco sin etiquetas. Los resultados mostraron que los modelos federados superaron a los modelos entrenados de forma aislada en términos de capacidad de generalización. Entre las estrategias evaluadas, el modelo Global obtuvo el mejor desempeño general, alcanzando un ROC-AUC de 0.8909, una precisión de 0.8295 y el mayor F1-score, lo que evidencia un equilibrio adecuado entre detección de fraude y control de falsas alarmas.

Asimismo, se observó que existe un compromiso natural entre Recall y Precision. Los modelos optimizados para maximizar la detección lograron identificar más del 90% de los fraudes, aunque a costa de un incremento considerable en la cantidad de falsos positivos. Este comportamiento es consistente con la naturaleza altamente desbalanceada de los problemas de fraude financiero.

Finalmente, la inferencia realizada sobre el Dataset 3 confirmó que los patrones aprendidos a partir de diferentes instituciones financieras pueden transferirse a nuevos entornos, permitiendo detectar operaciones potencialmente fraudulentas incluso en datos no observados durante el entrenamiento. Como trabajo futuro se propone explorar técnicas avanzadas de agregación federada, calibración de probabilidades y adaptación al dominio para mejorar aún más la robustez y precisión del sistema.

Referencias

Microsoft Corporation, LightGBM Documentation. [En línea]. Disponible en: <https://lightgbm.readthedocs.io/>. [Accedido: Jun. 2025].

International Organization for Standardization, ISO 8583: Financial Transaction Card Originated Messages. Geneva, Switzerland: ISO.

PLUS TI y Universidad del Valle de Guatemala, Trabajo Práctico 1: Métricas Custom para Reducción de Falsos Positivos y Entrenamiento de Modelo Federado, Guatemala, 2025.

P. P. Guzmán Mayén, A. Yatmian, J. Chen, Proyecto PlusTI: Detección de Fraude mediante Métricas Personalizadas y Aprendizaje Federado, GitHub Repository. [En línea]. Disponible en: https://github.com/PedroPabloGuzmanMayen/Proyecto_PlusTI. [Accedido: Jun. 2025].